

CHECKPOINT 03 — SMART ASSISTANT

Prompt Engineering & Artificial Intelligence — FIAP

Projeto: TechStore Smart Support

Domínio: Atendimento Inteligente para E-commerce

Integrantes

Luiz Garbeloto RM 567417

Emanuel Nabarrete RM566931

Eduardo Luiz RM567662

Miguel Bezerra RM566763

Lucas Mota RM566670

Introdução

O projeto TechStore Smart Support foi desenvolvido com o objetivo de aplicar na prática os conceitos aprendidos durante as aulas. Inicialmente, a proposta parecia simples, porém durante o desenvolvimento percebemos a importância de estruturar corretamente o pipeline, validar as respostas do modelo. O sistema foi construído em Python utilizando Ollama API com o modelo gpt-oss:120b, além de bibliotecas como Pydantic, Pandas e Matplotlib. Ao longo do projeto também aprendemos como Prompt Chaining, Guardrails e Structured Output são fundamentais para criar aplicações mais confiáveis e próximas de um ambiente real de produção.

Arquitetura do Projeto

A arquitetura foi baseada em Prompt Chaining com três etapas principais: classificação, processamento condicional e geração de resposta final. O pipeline possui Input Guards, validação com Pydantic e Output Guards para garantir segurança e consistência.

Fluxo do Pipeline

Fluxo completo: Input do usuário → Input Guardrails → Etapa 1 Classificação → Etapa 2 Processamento Condicional → Etapa 3 Resposta Final → Output Guardrails → Resposta ao Usuário.

Stack Técnica

O projeto utiliza Python 3.10+, Ollama API, modelo gpt-oss:120b, Pydantic para validação de JSON, Pandas e Matplotlib para análise de métricas e Tiktoken para contagem de tokens.

Structured Output com Pydantic

Todas as etapas retornam JSON validado por schemas Pydantic. Caso o JSON seja inválido, o sistema executa retry automático e fallback seguro.

Guardrails de Segurança

O sistema implementa Input Guards, System Prompt Defensivo e Output Guards. Foram bloqueados ataques como Prompt Injection, Jailbreak, DAN Mode e tentativas de vazamento do system prompt.

Framework de Prompt Engineering

O framework principal aplicado foi o CRISPE, definindo capacidade, papel, personalidade e comportamento do assistente. Também foram utilizados Persona Pattern e Template Pattern.

Evolução dos Prompts

Nos primeiros testes, o modelo apresentava respostas inconsistentes e nem sempre seguia o formato esperado. Por isso, fomos ajustando os prompts ao longo do projeto. Na versão final aplicamos o framework CRISPE, além de regras defensivas e separação de instruções com XML tags, melhorando a consistência e segurança das respostas.

Avaliação Automática

Foram criados datasets com 15+ solicitações legítimas e 5+ ataques de segurança. O sistema calcula acurácia, consistência, taxa de bloqueio, JSON válido e falsos positivos.

Métricas Obtidas

Acurácia de classificação: 92%. Taxa de JSON válido: 96%. Taxa de bloqueio: 100%. Taxa de falso positivo: 4%. Consistência: 94%.

Segurança e Ataques Testados

Foram testados ataques de Prompt Injection, Reveal Prompt, Jailbreak, Data Leakage e Rule Override. Todos os ataques foram corretamente bloqueados pelos guardrails.

Reflexão Final

O projeto ajudou o grupo a entender melhor como aplicações com LLMs precisam de validação, controle de contexto e mecanismos de segurança. Também percebemos como pequenas alterações no prompt podem impactar diretamente o comportamento do modelo. O uso de guardrails e Pydantic foi essencial para aumentar a confiabilidade do sistema.

Conclusão

O projeto atendeu aos requisitos do checkpoint, implementando pipeline multi-etapa, structured output, guardrails e avaliação automática. Além da parte técnica, o trabalho também contribuiu para entendermos melhor como construir aplicações de IA de forma mais segura e organizada.

Tabela de Métricas

Métrica	Resultado
Acurácia de Classificação	92%
Taxa de JSON Válido	96%
Taxa de Bloqueio	100%
Taxa de Falso Positivo	4%
Consistência	94%

Referências

- Documentação Oficial Python
- Documentação Pydantic
- Documentação Ollama
- Aulas 09, 10 e 11 da disciplina
- GitHub Models Documentation
- Anthropic Prompt Engineering Tutorial